命名实体识别项目说明

课程名称： 知识图谱

学号： 2018280186700 73

姓名： 刘浩林

2019 年 5 月 27 日

目录

一、NER 数据集的构建

本项目实现的功能是对**中文**命名实体进行识别，采用神经网络的方法进行识别（具体方法见 NER 识别方法），因此需要构建基于中文语料库的命名实体识别数据集，本项目通过爬取网页的新闻数据和已有的人民日报和 MSRA 中文语料库的基础上构建自己的命名实体识别数据集，常用的命名实体识别的标注方式有 BIO 和 BMEO 格式的标注方法，两种标注方法分别如图 1 和图 2 所示：

```
中      B-LOC
国      I-LOC
很      O
大      O

句      O
子      O
结      O
束      O
是      O
空      O
行      O
```

图 1. BIO 标注格式

```
美      B-LOC
国      E-LOC
的      O
华      B-PER
莱      I-PER
士      E-PER

我      O
跟      O
他      O
谈      O
笑      O
风      O
生      O
```

图 2.BMEO 标注格式

考虑到构建的数据集较大，且 BMEO 标注更为精细，所以项目采用 BMEO 格式对采集的数据进行标注。

使用 python 中的 pandas 进行**爬取搜狐和新华网的新闻数据**，网页设置如下图所示：（详见目录 NewCrawler\utils\news_crawler.py 文件）

```
sohu_template_url = 'http://v2.sohu.com/public-api/feed?scene=CHANNEL&sceneId=15&page=1&size={}'
xinhuanet_template_url = 'http://qc.wa.news.cn/nodeart/list?nid=11147664&pgnum={}&cnt={}&tp=1&orderby=1'
```

将爬取的数据按照 BMEO 标注格式进行标注得到命名实体数据集，因为爬取的数据较少，构成的命名实体个数较少，因此在此基础上下载了人民日报和 MSRA 的语料库，将语料库中的数据首先进行预处理，然后得到以 BMEO 命名实体标注的数据，为了实现不同算法和数据标注之间性能的比较，同样将上面的数据集以 BIO 格式进行标注了一份。得到的数据文件 Mydata 文件目录如下图所示：

```
├──boson
│       data_util.py
│       fyz.test.embs
│       origindata.txt
│       wordtagBIO.txt
│
├──MSRA
```

```
│       fyz.train.embs
│       test1.txt
│       testright1.txt
│       train1.txt
│       train2pkl.py
│       trainBIO.txt
│       wordtag.txt
│
└──renMinRiBao
        data_renmin_word.py
        devBIO.txt
        fyz.dev.embs
        renmin.txt
        renmintag.txt
```

图 3：数据集目录

说明：其中以 BIO 格式结尾的文件为 BIO 标注数据，以 embs 结尾的为 BMEO 标注的数据，Py 文件为进行数据处理的 python 文件。

制作的数据集的结果：项目中总共标注的实体有三类：人名、地名、机构名：

总共的实体数目统计如下面三个图所示：

```
C:\Users\Administrator\Desktop\ChineseNER-master\ChineseNER-master\data\boson>p
thon data_util.py
14801
finished tag
```

图 4. 14801 个实体

```
67653
finish taging the data
```

图 5.MSAR 67653 个实体

```
Bao>python data_renmin_word.py
43900
data tag finished
```

图 6. 人民日报 43900 个实体

上面的三个部分别作为测试集、训练集、验证集。

二、NER 方法

本次采用两种方法进行命名实体识别，一种采用常规的 BiLSTM+CFR 模型，但是加上 BERT 方法产生词向量，提升模型的性能，另外一种方法则采用,Lattice-CRF 模型来实现命名实体识别。

BERT+BiLSTM+CRF 方法介绍

常规的 BiLSTM+CRF 模型在老师的课件中有相关介绍，因此这里不再赘述，这里采用加入 BERT 方法来实现 BiLSTM+CRF 模型，BERT 方法主要用来产生词向量。大致的实现流程是

1）首先现将数据集制作成 BIO 格式，如图 1 所示。

2）然后将数据集转换成 BERT 需要的格式，如图 7、图 8 所示。

3）将数据封装成 record 形式，调用 BERT 官方的 API 实现数据读取、模型定义、模型训练。

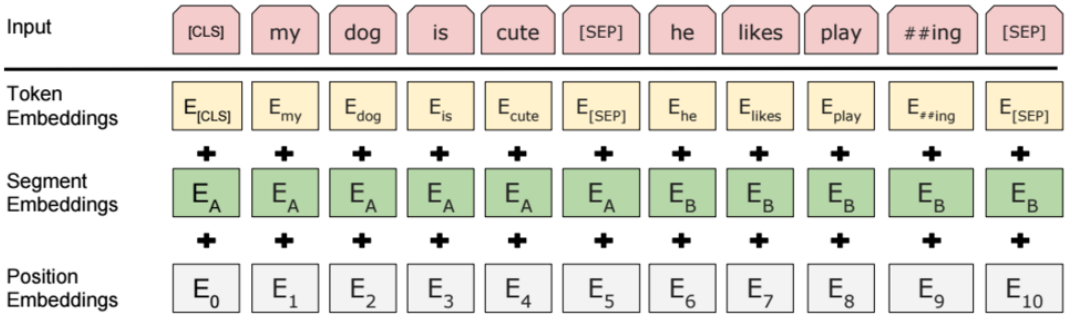

图 7. BERT 的数据格式

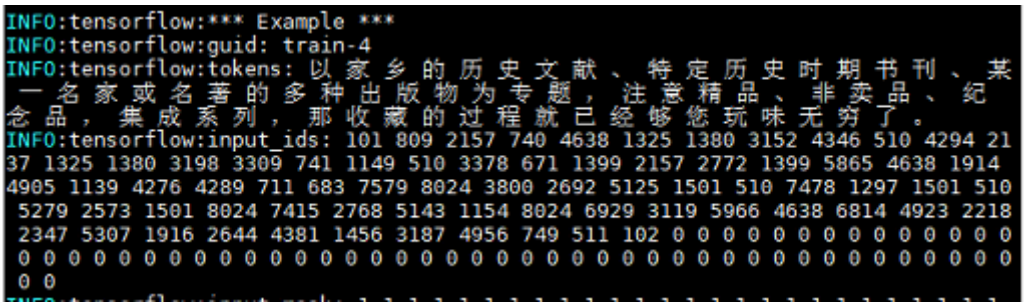

图 8. BERT 实际转换数据结果

Lattice-CRF 模型方法介绍：

Lattice-CRF 为 2018ACL 上面的文章，主要的设计思路为在中文实体识别时加入分词特征，使用预训练的分词特征来进行匹配语料库中的命名实体，主要设计思路如下图 9 所示：

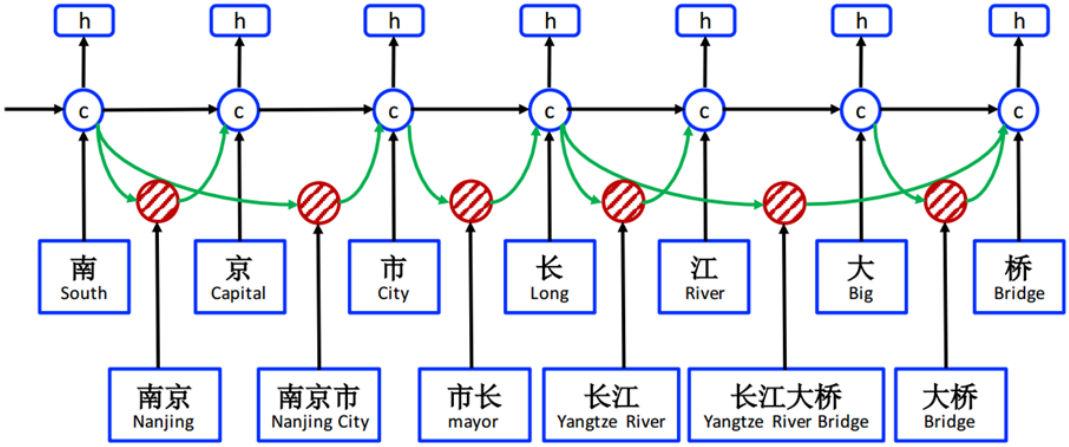

图 9. Lattice 模型设计思路

1）模型实现的大致步骤为首先将数据标注为图 2 所示的 BEMO 格式。
2）将预训练的分词特征加入进行词语间的匹配送入 RNN 模型当中。
3）训练、测试模型。

三、NER 项目运行流程

BERT+BiLSTM+CRF 方法

实验平台：Ubuntu18.0 +k80 GPU

软件及环境要求：

TensorFlow 版本：

```
>>> import tensorflow
>>> import tensorflow as tf
>>> tf.__version__
'1.12.0'
```

Python==3.6

训练及测试方法：

Ubuntu 下：python3 bert_lstm_ner.py

Lattice-CRF 模型方法:

实验平台：Ubuntu18.0 +k80 GPU

软件及环境要求：

Pytorch 版本：

```
>>> print (torch.__version__)
1.0.0
>>>
```

Python==3.6

训练及测试方法：

Ubuntu 下：python3 main.py

四、NER 项目测试性能指标

BERT+BiLSTM+CRF 方法：

1)在一个网上的较小的数据集上训练的结果

训练及测试结果如图 10 所示，红色的为测试的总的实体的准确度、召回率、F1 值，黄色的分别为三类不同的实体的识别的准确度、召回率、F1 值。

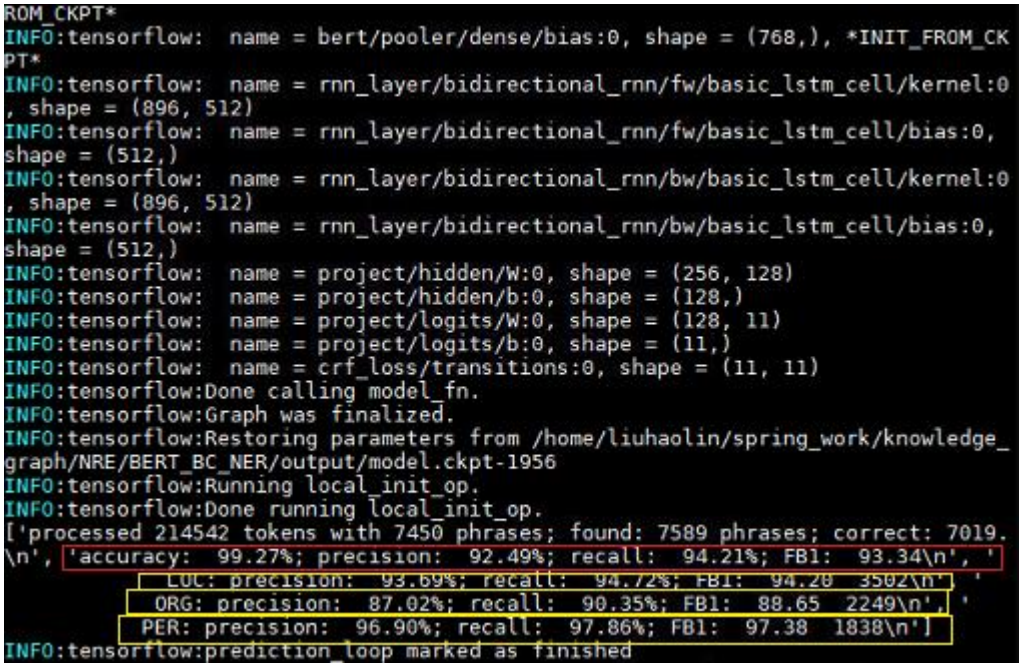

图 10. 测试结果图

具体的测试指标如下表 1 所示：

表 1.模型测试结果

实体类别	precision	recall	FB1
Total	92.49%	94.21%	93.34%
LOC	93.69%	94.72%	94.20%
ORG	87.02%	90.35%	88.65%
PER	96.90%	97.86%	97.38%

2)在自己制作的数据集上训练同一个测试集上测试的结果

训练及测试结果如图 11 所示，红色的为测试的总的实体的准确度、召回率、F1 值，黄色的分别为三类不同的实体的识别的准确度、召回率、F1 值。

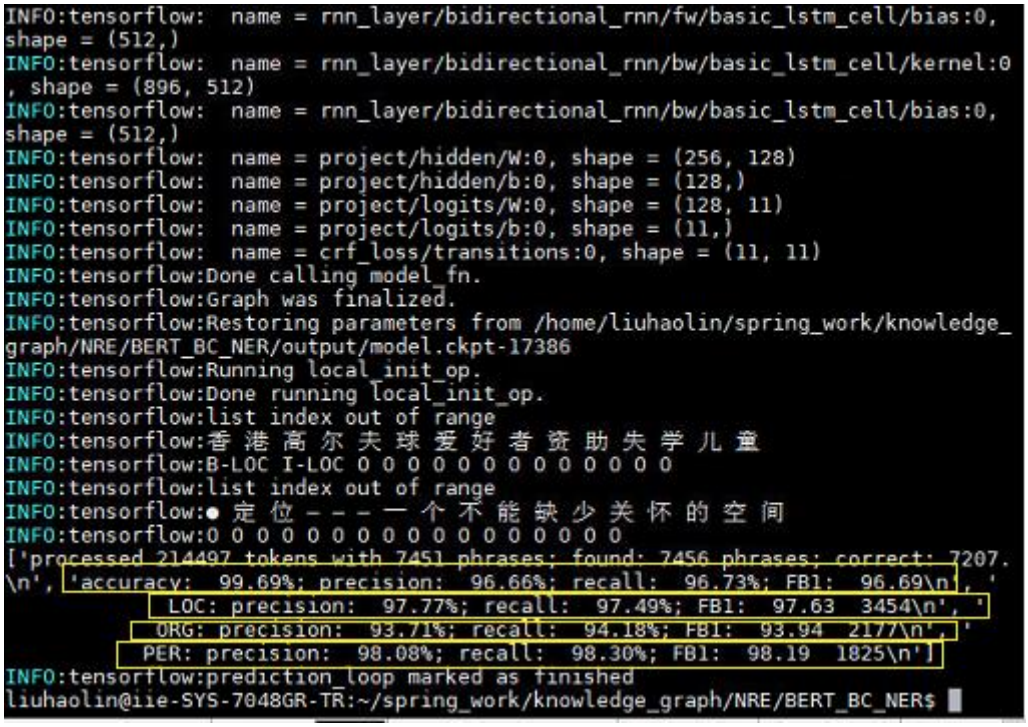

图 11. 测试结果图

具体的测试指标如下表 2 所示：

表 2.模型测试结果

实体类别	precision	recall	FB1
Total	96.66%	96.73%	96.69%
LOC	97.77%	97.49%	97.63%
ORG	93.71%	94.18%	93.94%
PER	98.08%	98.30%	98.19%

实验结果分析：对于该方法更换大的数据集以后模型的 F1 值显著提升，提升大约 3 个百分点，其他各项指标也显著提升。

Lattice-CRF 模型方法测试结果：

训练及测试结果如图 11 所示，红色方框中的迭代 100 个 epoch 测试中文实体的准确度、召回率、F1 值，以及速度。

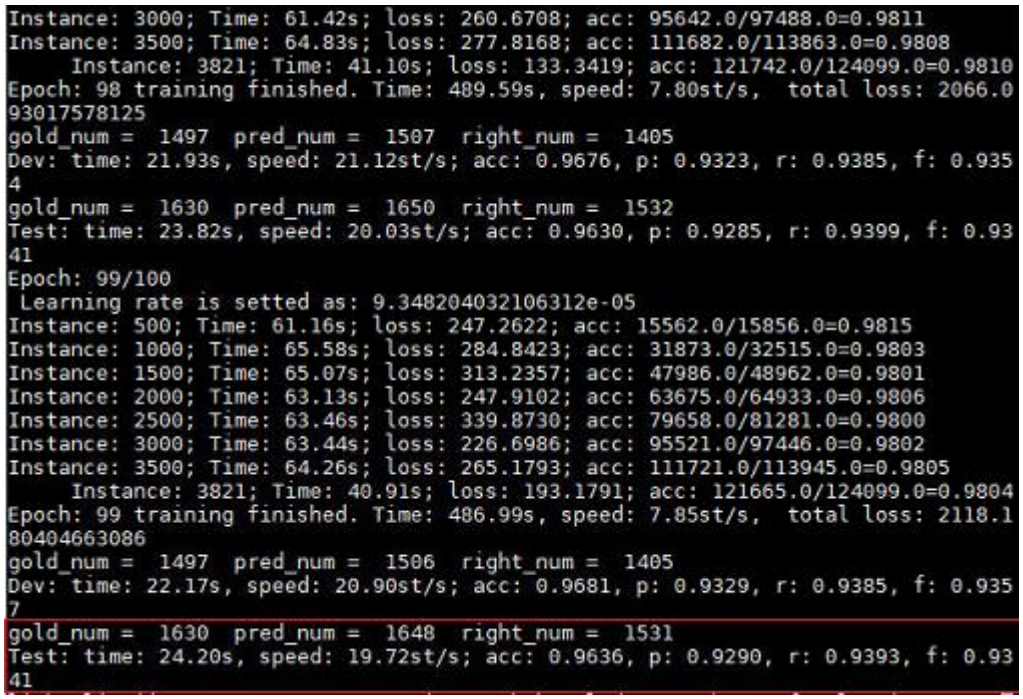

具体的测试指标如下表 2 所示：

表 2.模型测试结果

实体类别	precision	recall	FB1
Total	92.90%	93.93%	93.41%

思考与比较：

Lattice-CRF 模型方法在 F1 值上要略微高于 BERT+BiLSTM+CRF 方法，但是它的模型更复杂训练所需的时间更长，而 BERT+BiLSTM+CRF 方法则因为使用了 BERT 词向量的方法使得模型的性能上升，并且训练的时间也相对于 Lattice-CRF 模型更少，因此从工程上来说，BERT+BiLSTM+CRF 方法无疑更加占优势。

五、附录：代码结构图

```
├──BERT_BC_NER
│    │    bert_lstm_ner.py
│    │    conlleval.pl
│    │    conlleval.py
│    │    data.conf
│    │    lstm_crf_layer.py
│    │    tf_metrics.py
│    │
│    ├──bert
│    │    │    CONTRIBUTING.md
│    │    │    create_pretraining_data.py
│    │    │    extract_features.py
│    │    │    LICENSE
│    │    │    modeling.py
│    │    │    modeling_test.py
│    │    │    multilingual.md
│    │    │    optimization.py
│    │    │    optimization_test.py
│    │    │    README.md
│    │    │    requirements.txt
│    │    │    run_classifier.py
│    │    │    run_pretraining.py
│    │    │    run_squad.py
│    │    │    sample_text.txt
│    │    │    tokenization.py
│    │    │    tokenization_test.py
│    │    │    __init__.py
│    │    │
│    │    └──__pycache__
│    │              modeling.cpython-36.pyc
│    │              optimization.cpython-36.pyc
│    │              tokenization.cpython-36.pyc
│    │              __init__.cpython-36.pyc
│    │
│    ├──checkpoint
│    │    └──chinese_L-12_H-768_A-12
│    │              bert_config.json
│    │
│    ├──NERdata
│    │    │    dev.txt
│    │    │    test.txt
```

```
│   │   │   train.txt
│   │   │
│   │   ├──data
│   │   │       dev.txt
│   │   │       train(1).txt
│   │   │
│   │   └──ori
│   │           dev.txt
│   │           test.txt
│   │           train.txt
│   │
│   └──__pycache__
│           conlleval.cpython-36.pyc
│           lstm_crf_layer.cpython-36.pyc
│           tf_metrics.cpython-36.pyc
│
├──lattice_NER
│   │   fyz_run_decode.sh
│   │   main.py
│   │
│   ├──data
│   │   └──model
│   ├──model
│   │   │   bilstm.py
│   │   │   bilstmcrf.py
│   │   │   charbilstm.py
│   │   │   charcnn.py
│   │   │   crf.py
│   │   │   latticelstm.py
│   │   │   __init__.py
│   │   │
│   │   └──__pycache__
│   │           bilstm.cpython-36.pyc
│   │           bilstmcrf.cpython-36.pyc
│   │           charbilstm.cpython-36.pyc
│   │           charcnn.cpython-36.pyc
│   │           crf.cpython-36.pyc
│   │           latticelstm.cpython-36.pyc
│   │           __init__.cpython-36.pyc
│   │
│   ├──ResumeNER
│   │       .demo.raw.out.swo
│   │       .test.char.bmes.swp
│   │       dev.char.bmes
```

```
│   │       test.char.bmes
│   │       train.char.bmes
│   │
│   ├──test_data
│   │       fyz.dev.embs
│   │       fyz.test.embs
│   │       fyz.train.embs
│   │
│   └──utils
│       │   alphabet.py
│       │   data.py
│       │   functions.py
│       │   gazetteer.py
│       │   metric.py
│       │   trie.py
│       │   __init__.py
│       │
│       └──__pycache__
│               alphabet.cpython-36.pyc
│               data.cpython-36.pyc
│               functions.cpython-36.pyc
│               gazetteer.cpython-36.pyc
│               metric.cpython-36.pyc
│               trie.cpython-36.pyc
│               __init__.cpython-36.pyc
│
├──Mydata
│   ├──boson
│   │       data_util.py
│   │       fyz.test.embs
│   │       origindata.txt
│   │       wordtag.txt
│   │
│   ├──MSRA
│   │       fyz.train.embs
│   │       test1.txt
│   │       testright1.txt
│   │       train1.txt
│   │       train2pkl.py
│   │       trainBIO.txt
│   │       wordtag.txt
│   │
│   └──renMinRiBao
│           data_renmin_word.py
```

```
│               dev.txt
│               fyz.dev.embs
│               renmin.txt
│               renmintag.txt
│
└──NewsCrawler
    │   main.py
    │
    ├──news
    │       latest.txt
    │       latest_news.csv
    │       sohu.txt
    │       sohu_latest_news.csv
    │       xinhua.txt
    │       xinhuanet_latest_news.csv
    │
    └──utils
        │   news_crawler.py
        │   preprocessing.py
        │
        └──__pycache__
                news_crawler.cpython-37.pyc
                preprocessing.cpython-37.pyc
```